

expAsGrowth

实验即增长：AI 时代的增长方法论

何赞（展博） 著

展博增长实验室

版权声明

实验即增长：AI 时代的增长方法论

© 2026 何赞（展博） 版权所有

保留所有权利。未经作者书面授权，不得以任何形式或通过任何手段——电子、机械、复印、录音或其他方式——复制、传播、分发或存储本作品的任何部分。

本书内容基于作者在快手、Shopee 及出海游戏等领域的实践经验整理而成，仅供学习参考。书中提及的具体数据、案例和业务场景均已做脱敏处理。

如需咨询、陪跑或平台建设合作，请联系：

展博增长实验室

何赞（展博）

微信：zhanbo_growth

网站：<https://abtest.chat>

目录

- 第一章 总论：实验即增长的方法论
- 第二章 实验方法与产品增长
- 第三章 商业化中的实验应用
- 第四章 实验平台建设
- 第五章 买量中的实验应用
- 第六章 买量平台建设与广告平台拆解
- 第七章 总结：实验方法在各行业的应用

第一章 总论：实验即增长的方法论

1.1 为什么增长离不开实验


增长的本质是一个不断提问的过程，而不是一个一次性回答。每一个增长决策背后，都是对因果关系的追问：

- 改了新手引导，留存率真的提升了吗？
- 换了出价策略，ROAS 真的变好了吗？
- 调了广告频次，ARPU 和留存之间的平衡真的更优了吗？

这些问题无法靠经验直觉回答，因为**相关不等于因果**。我们观察到的指标变化，可能来自季节波动、市场趋势、用户结构变迁——而不是我们做的那个改动。

证据金字塔

科学界有一个「证据金字塔」，从低到高衡量证据的可信度：



在业务决策中，大量决策停留在「案例报告」和「观察性研究」层级——依赖个人经验或前后对比。而真正可靠的决策，需要 RCT（随机对照实验），即 A/B 实验。

增长是连续的实验链

增长不是一次灵光乍现的突破，而是一条连续的实验链：

1. **观察现象** → 发现某个指标异常或机会
2. **提出假设** → 明确"如果做 X，Y 会变"的因果假设
3. **设计实验** → 控制变量，分配流量，定义指标

- 4. 验证结论 → 用统计检验判断假设是否成立
- 5. 沉淀知识 → 将结论写入 playbook，指导后续决策

每一次实验都是一次学习。不实验，就没有学习；不学习，就没有积累；不积累，增长就是空中楼阁。

1.2 从「经验驱动增长」到「系统化增长」

经验驱动增长的问题

许多团队的增长模式是：

- 老板/总监凭直觉拍方向
- 运营凭经验调参数
- 投手凭手感选素材

这种模式的根本问题在于不可复制、不可积累、不可规模化。一个人离职，经验就流失；一个判断失误，代价可能巨大。

系统化增长的四个结果

将增长建立在实验系统之上，带来的不是单一指标的改善，而是四个系统性变化：

- 1. 降低决策风险 —— 不再赌直觉，用数据验证假设（先验指导后验）
- 2. 加速学习速度 —— 每次实验都有结论，每周都有新认知
- 3. 提高资源效率 —— 把预算花在验证有效的方向上
- 4. 增长复利效应 —— 实验结论沉淀为 playbook，后续决策越来越好

四个典型的实验场景

在出海游戏乃至更广泛的互联网产品中，实验覆盖四大场景：

场景	典型实验	核心指标
用户体验	新手引导、难度曲线、UI 布局、session 时长	D1/D7/D30 留存、session 数
产品功能	新玩法、社交功能、活动机制	参与率、留存、活跃度
买量/营销	素材测试、受众定向、出价策略、campaign 结构	CPI、ROAS、LTV/CAC
商业化	IAP 定价、IAA 广告频次、瀑布流策略、eCPM	ARPU、ARPPU、ad LTV

1.3 AI 时代，增长的逻辑没有变

很多人觉得 AI 时代一切都变了。但从增长方法论的角度看，变的只是工具，不是方法。

模型是工具，实验是方法

大模型可以做很多事：生成素材、优化出价、预测 LTV、自动化投放。但所有这些能力，最终都需要回答一个问题：它真的有效吗？

这个问题的答案只能通过实验得到。AI 生成的素材比人工素材 CPI 低 20%？需要实验验证。AI 优化的出价比人工出价 ROAS 高 15%？需要实验验证。

Intelligence vs Judgement

Sequoia（红杉资本）在 2025 年提出一个关键框架：Intelligence vs Judgement。

- **Intelligence**（智能）：模型可以提供的——分析数据、生成方案、执行操作
- **Judgement**（判断）：人必须保留的——选择方向、设定边界、评估风险

在增长系统中，AI 可以承担越来越多的 Intelligence（自动调价、自动素材生成、自动分析），但 Judgement（什么值得试、什么不能试、实验结论如何指导下一步）仍然需要人来决策。

这不是妥协，而是正确的分工。

从卖工具到卖结果


增长的交付模式也在演进：

阶段	卖什么	代表
1.0	卖工具	广告平台、BI 系统
2.0	卖工作	代投机构、自动化工具
3.0	卖结果	ROAS 保底、AI Agent 自主迭代

实验方法论在三个阶段都适用，但意义不同：在 1.0 阶段，实验帮你用好工具；在 2.0 阶段，实验帮你验证代理的产出；在 3.0 阶段，实验本身就是 Agent 的运行逻辑。

1.4 三元增长模型：产品 × 商业化 × 买量

对于出海游戏（以及大多数用户产品），增长不是单一维度的优化，而是三个引擎的闭环：



ad LTV	CPI
eCPM	ROAS

三个引擎互相制约：

- 产品留存决定 LTV 上限 → LTV 决定可承受的 CPI
- 买量的用户结构影响留存和 ARPU
- 广告策略太激进伤害留存 → 留存下降 → LTV 下降 → CPI 承受力下降
- 商业化收入决定买量预算 → 买量规模决定用户量 → 用户量决定数据量 → 数据量决定实验精度

因此，三类实验必须联动设计：

1. 产品实验提升留存 → 更高 LTV → 更高 CPI 承受力
2. 商业化实验优化 ARPU 与留存的平衡 → 更高 ad LTV
3. 买量实验找到可复制的获客组合 → 更低 CPI

任何单点优化如果不考虑闭环影响（很遗憾，这是目前大多数公司的现状），都可能得不偿失。

1.5 给小团队的三条建议

在建立复杂的实验平台之前，先养成三个习惯：

1. **先写假设，再动手优化** —— 把「我觉得改 X 会让 Y 变好」写成明确的因果假设
2. **每次只测一个变量** —— 多变量同时改，你永远不知道是哪个在起作用
3. **每次实验后沉淀结论** —— 写入 playbook，让团队每个人都能站在前人的肩膀上

增长不是玄学，是实验系统。

第二章 实验方法与产品增长

2.1 实验方法基础

什么是 A/B 实验

A/B 实验（随机对照实验，RCT）是因果推断的黄金标准。其核心逻辑是：

1. 将用户**随机**分为两组或多组
2. 给不同组施加**不同的处理**（feature variant）
3. 在**相同时间、相同环境**下观察指标差异
4. 用**统计检验**判断差异是否显著

随机化是关键——它确保了组间差异只来自处理本身，而不是其他混淆因素。

实验的完整生命周期

一个严谨的实验不是「开个实验看数据」，而是一个完整的流程：

提出假设 → 确定指标 → 计算样本量 → 分配流量 → 运行实验 → 统计检验 → 决策 → 沉淀结论

每一步都有常见的坑：

步骤	常见问题	正确做法
提出假设	模糊的「试试看」	写清因果：做 X → Y 变化 Z%
确定指标	指标太多或选错	区分 OEC（总体评估标准）和护栏指标
计算样本量	不算样本量，跑到哪算哪	根据最小可检测效应（MDE）和统计功效计算
分配流量	流量碰撞、互相干扰	使用重叠流量框架，做好实验互斥
运行实验	提前偷看、中途调参	固定时长，或使用序贯检验
统计检验	p 值误解、多重比较	理解 p 值含义，做多重比较校正
决策	统计显著但业务无意义	结合效应量和置信区间判断
沉淀结论	实验做完就忘	写入 playbook，关联到知识库

常用统计方法

方法	适用场景	说明
Welch's t 检验	连续指标均值比较	不假设等方差，比 Student's t 更稳健
卡方检验	比例类指标	转化率、留存率等
CUPED	降低方差、提高灵敏度	利用实验前数据减少噪声，等价于增加样本量
Delta Method	比率型指标的方差估计	如 $ARPU = Revenue / DAU$
序贯检验	需要提前停止的场景	控制 peeking 带来的假阳性膨胀
贝叶斯分析	需要实时决策的场景	给出 $P(B > A)$ 而非 p 值，更直观
Pre-AA 检验	实验前检查流量均匀性	实验开始前的空跑期，验证分组无系统性偏差

2.2 产品增长的核心指标体系

产品增长实验围绕留存展开。留存是所有后续增长的基石——没有留存，买量就是漏水的桶，商业化就是无源之水。

留存指标体系

指标	含义	用途
D1 留存	次日回访率	衡量首次体验质量
D7 留存	7 日回访率	衡量短期习惯形成
D30 留存	30 日回访率	衡量长期价值
Session 时长	单次使用时长	衡量沉浸度
Session 频次	日均打开次数	衡量使用频率
流失率	从活跃到不活跃的比例	留存的反面

漏斗指标

阶段	指标
安装 → 首次打开	安装转化率
首次打开 → 完成引导	引导完成率
完成引导 → 核心操作	核心功能渗透率
核心操作 → 重复使用	回访率

2.3 典型的产品实验设计

实验类型一：新手引导优化

假设：将 5 步引导简化为 3 步，D1 留存提升 5% 以上。

实验设计：

- 分组：A 组（5 步引导，对照组） vs B 组（3 步引导，实验组）
- 流量：50% / 50%
- 指标：OEC = D1 留存；护栏指标 = 引导完成率、核心功能渗透率
- 时长：14 天（确保覆盖足够的新用户）
- 样本量：根据基线 D1 留存率和 MDE = 5% 计算

常见陷阱：

- 引导步骤减少了，但用户不知道下一步该做什么 → 引导完成率升了，核心功能渗透率降了
- 必须同时看 OEC 和护栏指标

实验类型二：难度曲线调整

假设：将第 5-10 关的难度降低 20%，D7 留存提升 3%。

实验设计：

- 分组：A 组（原难度）vs B 组（降低难度）
- 流量：50% / 50%
- 指标：OEC = D7 留存；护栏指标 = 付费转化率（难度太低可能降低付费意愿）、通关率
- 时长：21 天

关键考量：

- 难度降低可能在短期内提升留存，但长期可能降低游戏粘性
- 需要关注 D30 留存和付费指标，不能只看 D7

实验类型三：社交功能上线

假设：添加排行榜功能，DAU 提升 2%，D7 留存提升 3%。

实验设计：

- 分组：A 组（无排行榜）vs B 组（有排行榜）
- 流量：50% / 50%
- 指标：OEC = D7 留存；辅助指标 = DAU、分享率、好友添加数
- 时长：28 天（社交功能需要更长时间观察网络效应）

关键考量：

- 社交功能有网络效应——用户量少时效果不明显，用户量多时效果放大
- 可能需要分阶段放量：5% → 20% → 50% → 100%

实验类型四：活动机制测试

假设：限时活动（7 天）比常驻活动提升 DAU 5%，但活动结束后 DAU 回落不超过 2%。

实验设计：

- 分组：A 组（常驻活动）vs B 组（限时活动）
- 流量：50% / 50%
- 指标：OEC = 活动 DAU 增量；护栏指标 = 活动后 7 天 DAU 回落幅度
- 时长：活动期 7 天 + 活动后观察 14 天 = 21 天

实验类型五：玩法变体测试

假设：新增「每日挑战」模式，参与用户的 D7 留存比未参与用户高 10%。

实验设计：

- 分组：A 组（无每日挑战）vs B 组（有每日挑战）
- 流量：30% / 70%（因为需要足够多的 B 组用户来观察参与 vs 未参与的差异）
- 指标：OEC = 整体 D7 留存（ITT 分析）；辅助 = 参与率、参与用户留存（CACE 分析）
- 时长：14 天

2.4 产品实验的三个分类

分类一：体验优化

这是最基础的产品实验，关注用户在产品内的体验：

- UI 布局调整
- 按钮位置和文案
- 加载速度优化
- 新手引导流程

特点：风险低、见效快、但天花板有限。

分类二：功能验证

验证新功能是否真正为用户创造价值：

- 新玩法上线
- 社交功能引入
- 个性化推荐
- 活动机制设计

特点：风险中等、见效周期长、但天花板更高。

分类三：方向选择

用实验回答战略级问题：

- 核心玩法是否需要大改？
- 社交方向（引入PVP） vs 单机方向（坚持PVE）？
- 内购为主 vs 广告为主？

特点：风险高、周期最长、但影响全局。这类实验通常不是简单的 A/B，而是多维度、多阶段的设计。

2.5 从单次实验到实验系统

单个实验的价值有限。真正的增长来自**实验系统和系统化实验**——一个持续产出、积累、复用实验结论的机制。

最小可行增长系统

即使没有复杂的平台，也可以建立最小可行的实验系统：

层级	内容	工具
基础数据层	漏斗、事件、归因、分群	事件 SDK + MMP
实验管理层	假设登记、分组管理、跨指标观察	电子表格 + 实验文档
决策看板层	产品看板、买量看板、商业化看板	BI 工具
周会机制	4 个问题：本周假设、实验进展、数据结论、下一步行动	周会

周增长会议的四问

1. 本周我们测试了哪些假设？
2. 实验进展如何（运行中/已结束/待分析）？
3. 数据告诉我们什么结论？
4. 基于结论，下一步做什么？

不回答这四个问题的增长会议，只是汇报会。

第三章 商业化中的实验应用

3.1 商业化实验的特殊性

商业化实验与产品实验有一个根本区别：**商业化实验往往涉及指标之间的权衡（trade-off）**。

产品实验通常追求单指标最优（留存越高越好），但商业化实验需要平衡两个方向相反的力：

- **多赚钱** → 加广告、提价格、增频次 → 但可能伤害用户体验
- **好体验** → 减广告、降价格、降频次 → 但可能减少收入

因此，商业化实验的核心不是“哪个方案好”，而是**找到收入与体验的最优平衡点**。

商业化的核心指标

指标	含义	计算方式
ARPU	每用户平均收入	总收入 / DAU

指标	含义	计算方式
ARPPU	每付费用户平均收入	付费收入 / 付费用户数
ARPPU	日均每活跃用户收入	日收入 / DAU
ad ARPU	广告人均收入	广告收入 / DAU
ad LTV	广告生命周期价值	广告 ARPU × 生命周期
eCPM	千次展示收入	(广告收入 / 展示次数) × 1000
付费转化率	付费用户占比	付费用户 / 总用户
IAP vs IAA 收入比	内购与广告收入结构	IAP 收入 / IAA 收入

关键权衡指标

权衡关系	实验必须同时观察
广告频次 ↑ → ARPU ↑ 但 留存 ↓	ad ARPU vs D1/D7 留存
广告位置显眼 → eCPM ↑ 但 体验差	eCPM vs session 时长
IAP 定价 ↑ → ARPPU ↑ 但 转化率 ↓	ARPPU vs 付费转化率
激励广告 → IAA 收入 ↑ 但 IAP 收入 ↓	IAA 收入 vs IAP 收入

3.2 典型的商业化实验设计

实验类型一：广告频次优化

背景：休闲游戏最主要的商业化方式是广告变现（IAA）。广告频次是最核心的杠杆——频次越高，收入越高，但用户体验越差。

假设：将激励视频的日展示上限从 10 次提升到 15 次，ad ARPU 提升 20% 以上，且 D1 留存下降不超过 2%。

实验设计：

- **分组：**A 组（10 次/天上限）vs B 组（15 次/天上限）
- **流量：**50% / 50%
- **指标：**
 - OEC：ad ARPU（预期 +20%）
 - 护栏指标：D1 留存（容许 -2%）、D7 留存（容许 -1.5%）、session 时长（容许 -5%）
- **时长：**21 天

关键考量：

- 不同用户群体对广告的容忍度不同——高活跃用户可能 15 次都点完，低活跃用户 5 次就烦了
- 需要做分群分析：按活跃度分层看效果
- 边际效应递减：从 10 → 15 次的收入增量，可能远小于 5 → 10 次的增量

进阶设计：不做统一上限，而是做**个性化频次**——根据用户的历史行为，对不同用户设定不同的频次上限。这本质上是一个 Uplift 模型 + 实验的组合。

实验类型二：广告位置测试

假设：在游戏结算页添加插屏广告，ad ARPU 提升 15%，且下一局启动率下降不超过 3%。

实验设计：

- **分组：**A 组（无结算页插屏）vs B 组（有结算页插屏）
- **流量：**50% / 50%
- **指标：**
 - OEC：ad ARPU
 - 护栏指标：下一局启动率、session 数、D1 留存
- **时长：**14 天

常见陷阱：

- 只看广告收入，不看用户行为变化 → 短期收入涨了，长期留存跌了
- 结算页是用户情绪高点（赢了一局），此时弹广告可能造成更强的负面体验

实验类型三：IAP 定价策略

假设：将入门礼包价格从 \$4.99 降至 \$2.99，付费转化率提升 30%，且 ARPPU 下降不超过 15%。

实验设计：

- **分组：**A 组（\$4.99）vs B 组（\$2.99）
- **流量：**50% / 50%
- **指标：**
 - OEC：IAP 总收入（= 转化率 × ARPPU）
 - 辅助：付费转化率、ARPPU、首次付费时间
- **时长：**28 天（付费决策周期较长）

关键考量：

- 价格锚定效应：降了价之后，用户对后续更高价位商品的接受度可能变化

- 需要跟踪付费用户 LTV，不只看首次付费
- 不同地区价格弹性不同 → 需要分地区分析

实验类型四：激励广告 vs 原生内购的替代效应

假设：增加激励视频奖励（多送 50% 游戏币），IAA 收入提升 25%，但 IAP 收入下降不超过 10%。

实验设计：

- **分组：**A 组（正常激励）vs B 组（激励 +50%）
- **流量：**50% / 50%
- **指标：**
 - OEC：总收入（IAP + IAA）
 - 护栏：IAP 收入占比（不应低于某个阈值）
 - 辅助：激励视频完成率、IAP 转化率
- **时长：**21 天

核心洞察：激励广告和内购之间存在替代关系。对于原本会付费的用户，如果激励广告能免费获得类似奖励，他们会选择看广告而非付费。实验必须同时衡量两个收入来源的变化。

实验类型五：用户分层商业化策略

假设：对高价值用户（历史付费 > \$10）降低广告频次 30%，对低价值用户保持高频次，总体收入不降，但高价值用户的 LTV 提升 15%。

实验设计：

- **分组：**
 - A 组（全量用户统一频次，对照组）
 - B 组（按付费历史分层，差异化频次）
- **流量：**50% / 50%
- **指标：**
 - OEC：总收入
 - 分群指标：高价值用户 LTV、低价值用户 ad ARPU
- **时长：**28 天

这是商业化实验的进阶形态——不再是简单的“加还是减”，而是“对不同的人怎么做不同事”。

3.3 瀑布流与 Header Bidding 的实验

对于以 IAA 为主的休闲游戏，广告瀑布流（Waterfall）和 Header Bidding 的配置是影响 eCPM 的关键杠杆。

瀑布流实验

假设：将 Ad Network B 从第 3 位置提升到第 2 位置，eCPM 提升 8%。

实验设计：

- **难点：**瀑布流变更通常通过广告平台（AppLovin MAX、ironSource 等）配置，不是在自有实验平台上做的
- **方法：**利用广告平台的 A/B 测试功能（如 MAX 的 Mediation A/B Testing），或通过分国家/分时段的准实验设计
- **指标：**eCPM、fill rate、ad ARPU

Header Bidding 实验

假设：在现有瀑布流基础上增加 Header Bidding 层，eCPM 提升 12%，且延迟增加不超过 100ms。

实验设计：

- **方法：**通过 MAX 的 Bidding A/B Testing 功能
- **指标：**eCPM、ad ARPU、广告加载延迟、展示率

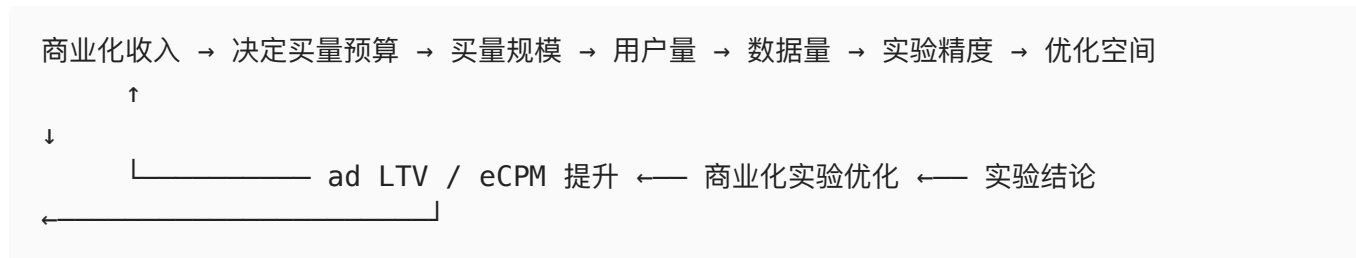
商业化 A/B 测试的注意事项

1. 广告平台的实验能力有限 —— 不如自建实验平台灵活
2. 流量分配粒度粗 —— 通常按国家/设备类型分，无法精确到用户级
3. 需要等待填充率稳定 —— 新配置上线后需要 3-5 天数据稳定期
4. 跨平台影响 —— AppLovin MAX 的变更可能影响 AdMob 的填充

3.4 商业化与产品、买量的联动

UA-变现飞轮

商业化不只是「怎么赚钱」，它直接影响买量的经济模型：



关键联动：

联动场景	说明
ad LTV 提升 → CPI 承受力提升	商业化实验成功后，买量可以承受更高的 CPI，获客空间扩大
买量用户结构变化 → ARPU 变化	新渠道的用户可能 ARPU 更低，需要重新评估买量 ROI
产品留存变化 → LTV 变化 → 买量模型变化	留存提升直接提升 LTV，间接扩大买量空间
广告策略太激进 → 留存下降 → LTV 下降	商业化短视会损伤增长根基

三类实验必须联动设计

- 1. 产品实验提升留存 → 更高 LTV → 更高 CPI 承受力
- 2. 商业化实验优化 ARPU 与留存的平衡 → 更高 ad LTV
- 3. 买量实验找到可复制的获客组合 → 更低 CPI

任何单点优化如果不考虑闭环影响，都可能得不偿失。例如：

- 产品为了留存砍掉广告位 → 留存涨了但收入暴跌 → 买量预算缩水 → 获客下降
- 买量为了 CPI 便宜引入低质量用户 → ARPU 下降 → 商业化收入下降 → 预算缩水

3.5 商业化实验的决策框架

面对商业化实验，需要回答三个问题：

- 1. 收入会变吗？ → 看 OEC（总收入或 ad ARPU）
- 2. 体验会变吗？ → 看护栏指标（留存、session 时长）
- 3. 结构性影响是什么？ → 看 IAP/IAA 收入占比、分群效果

只有三个问题都有清晰答案，才能做出正确的商业化决策。

第四章 实验平台建设

4.1 为什么需要实验平台

没有实验平台，也能做实验——手动分流、手动看数据、手动算 p 值。但这样的实验无法规模化：

- 流量冲突：多个实验同时跑，互相干扰，结论不可信

- **结论流失**：实验做完，结论在人的脑子里，人走了知识就没了
- **效率低下**：每次实验都要重复搭建基础设施
- **质量失控**：p 值误解、偷看数据、样本量不足等问题反复出现

实验平台的目标不是「能做实验」，而是**让正确的实验可以大规模、低成本、高质量地持续运行**。

实验平台的四个核心能力

能力	说明
流量管理	分流、互斥、重叠、分层
实验管理	实验生命周期、假设登记、版本控制
统计分析	假设检验、方差缩减、多重比较校正
指标体系	OEC 定义、护栏指标、指标敏感度

4.2 重叠流量框架

从互斥分流到重叠分流

互斥分流 (Mutual-Exclusion) 是最简单的分流方式：将用户分成 N 个桶，每个实验独占一组桶。

```
用户 ID → Hash → 桶号 (1-100)
实验 A: 桶 1-50 (对照组 1-25, 实验组 26-50)
实验 B: 桶 51-75 (对照组 51-62, 实验组 63-75)
实验 C: 桶 76-100 (对照组 76-87, 实验组 88-100)
```

问题：实验数量受限于桶数。100 个桶最多同时跑 3-4 个实验，远不够用。

重叠分流 (Overlapping / Layered) 的核心思想：将流量分为多个**层 (Layer)**，每层内部独立分流，不同层之间流量正交。

```
层 1 (UI 层): 桶 1-50 → 实验 A, 桶 51-100 → 对照
层 2 (算法层): 桶 1-30 → 实验 B, 桶 31-70 → 实验 C, 桶 71-100 → 对照
层 3 (商业化层): 桶 1-50 → 实验 D, 桶 51-100 → 对照
```

关键：同一用户在不同层被独立分配，层与层之间流量正交，互不影响。

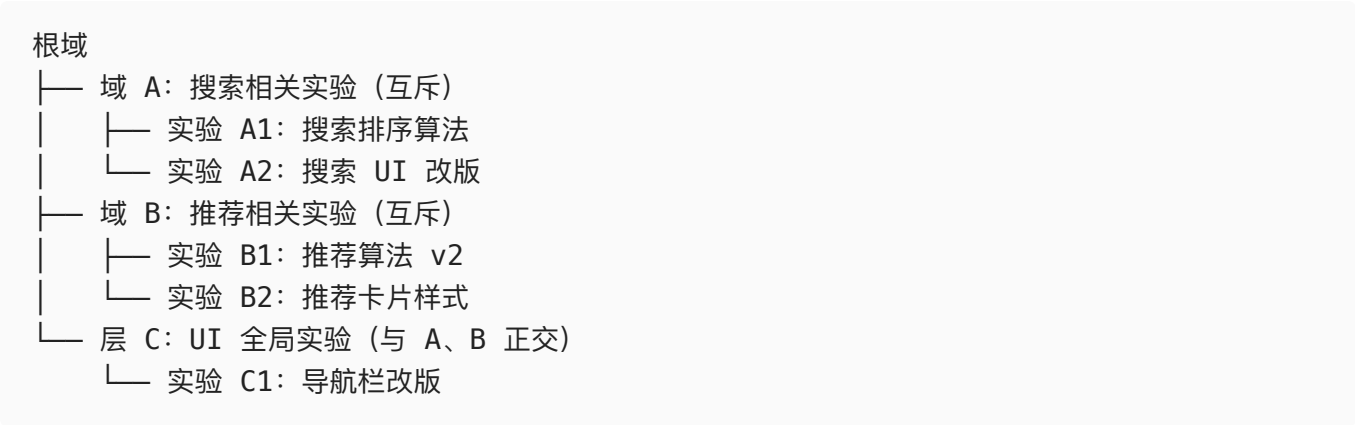
正交性保证

重叠框架的前提是**层间正交**——用户在 A 层的分组不影响其在 B 层的分组。实现方式：

- 1. 分层 Hash：Hash(Layer_ID + User_ID) % 100，不同 Layer_ID 产生独立分布
- 2. 验证正交性：通过 Pre-AA 检验（空跑期），验证各层分组在关键指标上无系统性偏差

域（Domain）与子域

当实验之间可能存在交互效应时，需要将它们放在同一域内互斥运行：



4.3 分流方法与数据回收

分流方法

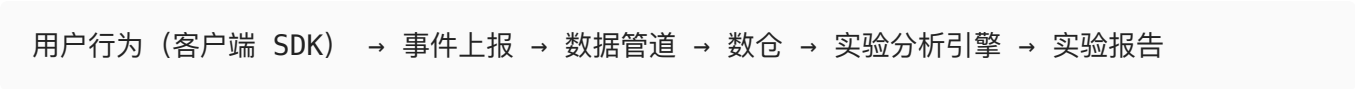
方法	适用场景	说明
用户 ID 分流	大多数产品实验	同一用户始终在同一组
设备 ID 分流	无账号体系的产品	同一设备始终在同一组
Session 分流	无持续身份的场景	每次 session 独立分流
地域分流	地理差异大的实验	按国家/地区分组
时间片分流	无法用户级分流的场景	按时间段交替切换

分流的关键原则

- 1. 一致性：同一用户（同一分流键）始终在同一实验组
- 2. 随机性：分组在所有维度上无系统性偏差
- 3. 可扩展性：新增实验不影响已有实验的分组
- 4. 可验证性：可以通过 Pre-AA 检验验证分组质量

数据回收

实验数据的回收链路：



关键问题：

- 1. 事件质量：上报是否完整、准确、及时
- 2. 归因链路：用户行为是否正确关联到实验分组
- 3. 数据延迟：实时 vs T+1，不同场景需要不同时效
- 4. 跨端一致性：用户在 App 端和 Web 端的实验分组是否一致

曝光（Exposure）日志

实验效果的度量前提是准确记录用户何时被暴露于实验。曝光日志不是简单的"用户属于实验组"，而是"用户何时、在哪个场景下、被暴露了哪个实验版本"。

```
曝光日志示例：
{
  "user_id": "u12345",
  "experiment_id": "exp_001",
  "variant_id": "treatment_b",
  "layer_id": "layer_ui",
  "exposure_time": "2026-06-15T10:23:45Z",
  "exposure_scene": "game_result_page"
}
```

4.4 指标检验与实验报告

指标设计

类型	说明	示例
OEC（总体评估标准）	实验最核心的判断指标	D7 留存、总收入
护栏指标	不能恶化的底线指标	D1 留存、崩溃率
诊断指标	帮助理解实验为何有效/无效	参与率、功能渗透率
分群指标	不同用户群体效果是否不同	新老用户、高低活跃

统计检验流程

- 1. 计算每组的指标均值和标准误
- 2. 构建检验统计量（t 值 / z 值）
- 3. 计算 p 值或置信区间
- 4. 判断统计显著性（通常 $p < 0.05$ ）
- 5. 评估效应量的业务意义
- 6. 做出决策：全量上线 / 不上线 / 继续实验

实验报告模板

一份完整的实验报告应包含：

实验报告：[实验名称]

基本信息

- 实验假设：做 X → Y 变化 Z%

- 运行时间：2026-06-01 ~ 2026-06-14

- 流量分配：50% / 50%

- 样本量：对照组 N1，实验组 N2

结论

- OEC (D7 留存)：+3.2% (p=0.012)，统计显著

- 护栏指标 (D1 留存)：-0.5% (p=0.34)，统计不显著

- 诊断指标 (功能渗透率)：+8% (p=0.003)

分群分析

- 新用户：+5.1% (显著)

- 老用户：+1.2% (不显著)

决策

- 结论：全量上线

- 理由：OEC 显著提升，护栏指标无恶化

- 后续：观察 D30 留存的长期影响

Playbook 记录

- 结论编号：EXP-2026-042

- 可复用洞察：简化引导流程对新用户 D7 留存有显著正向效果

4.5 实验平台建设案例

以下是作者本人参与的实验平台建设案例。

案例一：快手实验平台升级（2019-2021）

背景：早期实验系统基于 Python 构建，存在流量碰撞、p 值误解、无结论沉淀等问题。

核心升级：

- 从互斥分流升级为**重叠流量框架**，实验并发量从 100+ 提升到 1000+
- 引入 **Pre-AA 检验**，实验前自动验证分组均匀性
- 建立**指标体系**，区分 OEC、护栏、诊断三类指标
- 建设**实验报告**标准化流程，强制要求实验结论沉淀

关键经验：内容平台的实验密度极高（推荐、搜索、广告、UI 每天都在迭代），重叠框架是必须的选择。

案例二：Shopee 实验平台统一（2022-2025）

背景：各业务线（搜索、推荐、广告）各自建设了实验平台，互不兼容，流量冲突频发。

核心升级：

- **统一平台：**合并分散的实验平台为一个统一入口
- **嵌套流量域：**搜索域、推荐域、广告域各自独立，但共享基础分流层
- **自动化放量：**实验结论显著后，支持自动从 5% → 50% → 100% 逐步放量
- **搜索-推荐-广告合并实验：**支持跨域联合实验，验证推荐改搜索、广告改推荐等跨域影响

关键经验：电商平台的搜索、推荐、广告高度耦合，实验平台必须支持跨域分析，否则会漏掉交互效应。

案例三：出海游戏实验平台升级（2025）

背景：原有互斥桶方案限制了实验并发，游戏上线后功能迭代加速，实验需求爆发。

核心升级：

- 从互斥桶升级为**重叠框架**，实验并发能力从 ~10 提升到 1000+
- 引入 **CUPED** 方差缩减技术，在样本量有限的情况下提高检验灵敏度
- 引入**贝叶斯分析**，支持更灵活的决策（如"有 95% 概率 B 组优于 A 组"）
- 支持**商业化和买量场景的实验**，不局限于产品功能

关键经验：游戏 DAU 可能不如内容平台和电商，但实验密度不低。CUPED 和贝叶斯分析在小样本场景下特别有价值。

4.6 实验文化的建设

平台只是工具，**实验文化**才是让平台发挥价值的根本。

常见的实验文化问题

问题	表现	解决方案
不做实验就上线	"我确信这个改版是对的"	强制要求所有功能变更走实验流程
p 值误解	"p < 0.05 就说明效果好"	培训：p 值是"假阳性概率"，不是"效果好的概率"
偷看数据	每天看数据，好了就停	使用序贯检验或固定时长
实验做完就忘	没有结论沉淀机制	强制写实验报告，关联到 playbook

问题	表现	解决方案
流量碰撞	多个实验互相干扰	重叠流量框架 + Pre-AA 检验

六维度实验诊断框架

评估一个团队的实验能力，从六个维度打分：

维度	评估要点
流量管理	是否支持重叠分流？分组是否可验证？
实验管理	是否有完整的实验生命周期管理？
统计分析	是否使用 CUPED 等方差缩减？是否处理多重比较？
指标体系	是否区分 OEC / 护栏 / 诊断指标？
工程架构	数据回收链路是否完整？延迟是否可控？
实验文化	是否有实验结论沉淀机制？团队是否习惯先假设后实验？

30/60/90 天路线图

阶段	目标	关键动作
30 天	诊断	完成六维度评估，识别最大瓶颈
60 天	基础建设	上线重叠框架，建立实验管理流程，定义指标体系
90 天	文化建设	培训统计分析基础，建立实验报告规范，启动 playbook

4.7 AI 驱动的实验平台演进

AI 应用交付的七层模型

实验平台在AI方向的演进也可以借鉴 AI 应用的交付框架——从业务指标出发，反向设计：

层级	AI应用	实验平台对应
L1 业务指标	ROI、效率、规模、质量等指标	实验驱动增长的业务目标（留存、收入、ROAS）
L2 业务抽象	产品迭代、UA买量、商业化变现等流程和具体环节	实验场景定义（产品、商业化、买量四类实验）
L3 应用设计	UA买量核心用例：创建计划、效果监控、调整计划、竞品情报	实验管理界面、指标计算和检验、实验报告、playbook 知识库（已有实验平台基础上进行拓展和适配）

层级	AI应用	实验平台对应
L4 流程编排	UA买量流程：自动执行、低风险，模型主导、中风险，人工确认、高风险，严格审批	实验生命周期自动化（假设→设计→运行→分析→决策→沉淀）
L5 上下文工程	历史对话、业务上下文、平台上下文、Schema（媒体）上下文、RAG检索（历史案例）	实验上下文（历史实验、指标基线、用户分群特征）
L6 模型调用	意图理解、任务拆解、配置生成、复杂推理、代码生成、创意生成等	实验目标以及实验创意的生成、实验报告的解读
L7 模型能力	多模态理解、多模态生成支持的对话和推理	一致的底层模型能力

设计原则：从 L1 出发向下设计，而不是从 L7 出发向上堆砌。

Agent-Ready Measurement

实验平台的终极形态是**Agent 可自主运行实验**：

- 1. Agent 提出假设（基于历史数据 pattern）
- 2. Agent 设计实验（选择分流策略、计算样本量）
- 3. Agent 运行和监控实验（异常检测、提前停止）
- 4. Agent 分析实验结果（统计检验、分群分析）
- 5. Agent 沉淀结论（写入 playbook、更新知识库）

但每一步都需要人在环中（**Human-in-the-loop**）的审批：这是 Judgement，不是 Intelligence。

AI在实验平台演进中的另一个方向是进行流量的拟合，即构建实验沙箱，一定程度摆脱对现实世界和真实用户行为的依赖，可以进行一些前置的探索性实验。这里不重点展开。

第五章 买量中的实验应用

5.1 买量实验的特殊性

买量（User Acquisition, UA）实验与产品/商业化实验有本质区别：

维度	产品实验	买量实验
分流主体	已有用户	新用户（尚未到达）
控制力度	完全可控	受广告平台算法影响

维度	产品实验	买量实验
指标时效	实时可观测	归因延迟（SKAN、MMP）
样本来源	全量用户	仅为被广告触达的用户
干扰因素	较少	竞品出价、平台策略、素材疲劳

买量实验的核心挑战是你无法完全控制流量的分配——广告平台决定了谁看到你的广告。你只能控制素材、出价、受众、预算这些输入变量，然后观察平台算法分配给你的结果。

5.2 买量实验的核心指标

效率指标

指标	含义	计算方式
CPI	每次安装成本	花费 / 安装数
CPM	千次展示成本	花费 / 展示次数 × 1000
CTR	点击率	点击数 / 展示数
CVR	转化率	安装数 / 点击数
ROAS	广告支出回报率	回收收入 / 广告花费
LTV/CAC	生命周期价值 / 获客成本	LTV / CPI

质量指标

指标	含义	为什么重要
D1/D7 留存（按渠道）	不同渠道用户的留存	低留存渠道=浪费钱
ARPU（按渠道）	不同渠道用户的人均收入	高 CPI + 高 ARPU 可能比低 CPI + 低 ARPU 更优
付费率（按渠道）	不同渠道用户的付费转化	付费用户是 LTV 的核心贡献者
素材疲劳度	同一素材 CTR 随时间下降的速率	决定素材更新频率

5.3 典型的买量实验设计

实验类型一：素材 A/B 测试

假设：新素材 B（游戏实机画面）比素材 A（CG 动画）CPI 低 15%。

实验设计：

- 方法：在同一个 Campaign 下，创建两个 Ad Set，分别使用素材 A 和 B
- 控制变量：受众、出价、预算、投放时段完全一致
- 指标：OEC = CPI；辅助 = CTR、CVR、D1 留存
- 时长：7-14 天（素材效果需要时间稳定）

常见陷阱：

- 学习期污染：广告平台有学习期（通常 50 次转化），学习期内数据不稳定 → 排除前 3 天数据
- 预算不均：平台算法倾向于把预算分配给效果好的素材 → 自然分配不均 → 无法公平比较
- 素材疲劳速度不同：素材 A 可能前 3 天好、后 4 天差，素材 B 反之 → 看整体均值可能掩盖趋势

进阶设计：使用 CBO（Campaign Budget Optimization）让平台自由分配预算，然后用增量分析（而非直接比较 CPI）来判断素材效果。

实验类型二：受众定向测试

假设：Lookalike 受众比 Broad 受众 ROAS 高 20%。

实验设计：

- 方法：同一 Campaign 下，创建两个 Ad Set，分别使用 Lookalike 和 Broad
- 控制变量：素材、出价、预算
- 指标：OEC = D7 ROAS；辅助 = CPI、D1 留存
- 时长：14 天（需要足够时间积累 ROAS 数据）

关键考量：

- Lookalike 受众规模有限，预算打到一定程度会撞天花板
- Broad 受众虽然 ROAS 可能低，但可扩展性更强
- 需要在"效率"和"规模"之间找平衡

实验类型三：出价策略测试

假设：从 Manual CPC 切换到 Target ROAS 自动出价，ROAS 提升 15%，且日均消耗不低于当前水平。

实验设计：

- 方法：同一 Campaign 下创建两个 Ad Set，一个 Manual CPC，一个 tROAS
- 控制变量：受众、素材

- 指标：OEC = ROAS；护栏 = 日均消耗（不能大幅下降）；辅助 = CPI、CVR
- 时长：21 天（自动出价算法需要较长学习期）

关键考量：

- 自动出价在学习期（3-7 天）数据不可靠
- tROAS 设定值直接影响结果——设太高，花不出去钱；设太低，ROAS 看起来好但浪费机会
- 需要测试多个 tROAS 目标值，不是一个定论

实验类型四：Campaign 结构测试

假设：ASC（Advantage+ Shopping Campaign）比手动 Campaign 结构 ROAS 高 10%。

实验设计：

- 方法：A/B Campaign 测试——创建两个完全独立的 Campaign
- 控制变量：总预算一致、素材一致
- 指标：OEC = ROAS；辅助 = CPI、CVR、D7 留存
- 时长：21 天

关键考量：

- ASC 是 Meta 的自动化方案，内部算法不透明
- 两个 Campaign 之间不存在用户级分流，只能做地理区域分流或时间片分流
- 结论的因果性弱于产品实验，但仍是买量场景下最可用的方法

实验类型五：预算分配实验

假设：将 Google Ads 预算从 60% 提升到 70%，总 ROAS 提升 5%。

实验设计：

- 方法：跨渠道预算调整实验
- 控制变量：总预算不变，只调整分配比例
- 指标：OEC = 总 ROAS；辅助 = 各渠道 CPI 和 ROAS
- 时长：14 天


关键考量：

- 跨渠道实验的分流更难——无法在同一渠道内分流
- 需要用时间片或地理区域作为分流单元
- 注意渠道间的协同效应：某渠道预算增加可能影响其他渠道的表现（品牌搜索量变化等）

5.4 素材疲劳与更新节奏

素材疲劳的规律

几乎所有买量素材都遵循**疲劳曲线**：



典型节奏：

- 学习期（1-3 天）：CTR 从低到高，平台在找对的人
- 稳定期（3-14 天）：CTR 维持在高位
- 疲劳期（14 天+）：CTR 持续下降，同批受众已看过多次

素材更新实验

假设：每 10 天更新一轮素材，比每 20 天更新一轮的 CTR 高 25%。

实验设计：

- 方法：A/B Campaign，A 组每 20 天换素材，B 组每 10 天换素材
- 指标：OEC = 平均 CTR 和 CPI；辅助 = 素材制作成本、CVR
- 时长：40 天（覆盖 2 个 B 组更新周期和 1 个 A 组更新周期）

素材实验的闭环

数据洞察（哪些素材类型 CTR 高）→ 素材生成 → 素材 A/B 测试 → 胜出素材上线 → 监控疲劳 → 下一轮

AI 可以加速这个闭环中的「素材生成」环节，但「数据洞察」和「A/B 测试」仍然需要实验方法论。

5.5 新广告渠道的实验：AI 搜索广告

2026 年的渠道变局

2026 年是搜索广告向对话式广告的拐点：

渠道	状态	特点
Google AI Mode	2026 Q4 全面上线	广告嵌入 AI 生成回答中
ChatGPT Ads	2026-06-05 生效	Sponsored Cards in conversation, CPA 模式
Perplexity / Claude	暂无广告	优先做 GEO (Generative Engine Optimization)

ChatGPT Ads 实验设计

假设：ChatGPT Ads 的 CTR 为 8%（远高于传统展示广告的 2-3%），但转化率需要验证。

实验设计：

- 方法：小预算测试（\$50/天），跑 14 天
- 指标：CTR、CVR、CPA、D1 留存
- 关键动作：部署 ChatGPT Conversion Pixel，设置 UTM 标准化参数

GEO 实验设计

假设：优化网站结构化数据（Schema.org）和 FAQ 页面后，AI 搜索引擎的品牌提及率提升 30%。

实验设计：

- 方法：对比优化前后的 AI 搜索品牌提及率
- 指标：品牌提及率、AI 搜索导流量、转化率
- 关键动作：部署 llms.txt、优化 OAI-AdsBot 白名单

5.6 买量实验的决策框架

月消耗金额与实验策略

月消耗	策略	实验能力
< \$20K	小预算快速验证	每次只测一个变量，2-3 个实验并行
\$20K-\$100K	系统化实验	素材 + 受众 + 出价三维实验矩阵
\$100K-\$300K	多渠道联合实验	跨渠道预算分配实验、渠道协同实验
> \$300K	全面实验体系	渠道 x 素材 x 受众 x 出价的完整实验矩阵

托管 vs 自投的实验视角

模式	实验能力	说明
托管（Agency）	依赖代理的实验能力	数据不在自己手里，实验结论不可积累
自投	完全掌控实验设计	数据、结论、playbook 完全自主
混合	分阶段迁移	从托管开始，逐步建立自投实验能力

核心判断：代理卖的是执行，不是能力。如果你依赖代理做买量，你永远无法积累自己的实验知识。最终，你必须建立自己的买量实验体系。

第六章 买量平台建设与广告平台拆解

6.1 买量平台的成熟度模型

买量平台不是一步建成的，而是从信息可视化到策略自动化的渐进过程。

L0-L5 成熟度模型

层级	名称	能力	典型特征
L0	信息孤岛	各平台各自为战	人工导出报表、Excel 汇总
L1	信息可见	数据汇聚到一处	自动化数据拉取、统一看板
L2	数据打通	跨平台数据关联	MMP 归因 + 平台数据 + 内部数据关联
L3	效率工具	减少重复操作	自动化规则、批量操作、素材管理
L4	策略辅助	辅助决策	预算建议、出价优化、素材推荐
L5	策略自动化	Agent 自主迭代	AI Agent 自主调价、自动素材生成和测试

各层级的关键建设内容

L0 → L1：数据基础

- 对接 Google Ads、Meta Ads、TikTok Ads 等 API
- 自动化数据拉取（每 4-6 小时）
- 统一费用、安装、事件的数据口径
- 基础看板：花费、CPI、ROAS 按渠道/国家/素材

L1 → L2：数据打通

- MMP 归因数据整合（AppsFlyer / Adjust / Singular）

- 广告费用 + 归因 + 应用内事件关联
- 用户 LTV 计算 (D7/D30 ROAS)
- 分群分析 (渠道 × 国家 × 素材 × 用户价值)

L2 → L3: 效率工具

- 自动化规则 (CPI > \$X 暂停、ROAS < Y% 降预算)
- 批量操作 (一键调价、一键开关)
- 素材管理 (上传、标签、A/B 测试管理)
- 报表自动化 (日报、周报自动生成)

L3 → L4: 策略辅助

- 预算分配建议 (基于历史 ROI 和增量估算)
- 出价优化建议
- 素材疲劳预警
- 竞品监控

L4 → L5: 策略自动化

- AI Agent 自主调价
- 自动素材生成和 A/B 测试
- 自动放量/缩量
- 人审批 → Agent 执行 → Agent 汇报

6.2 三大平台能力：广告主侧、媒体侧、流量主侧

买量不只是「花钱买用户」。要真正理解买量，需要从三个视角理解广告生态：

广告主侧 (Advertiser Side)

关注点：如何高效地花钱买用户。

核心能力：

- 跨媒体 Campaign 管理
- MMP 归因和事件回传
- 自动化规则和出价策略
- 素材测试管理
- 预算分配和 ROI 监控

数据源：

- 一方数据：SDK/MMP 事件数据
- 二方数据：广告平台数据（Google Ads / Meta Ads / TikTok Ads）
- 三方数据：行业 benchmark

媒体/DSP 侧（Media / DSP Side）

关注点：广告平台如何决定把流量给你。

理解广告投放的底层逻辑：

广告索引 → 召回 → 排序 → 竞价 → 预算控制 → 展示

影响你获量的关键因素：

因素	说明	你能做什么
CTR / CVR 预估	平台预估你的广告点击率和转化率	优化素材、优化落地页
出价策略	你的出价和出价方式	选择合适的出价策略（CPC/CPA/tROAS）
预算节奏	平台如何分配你的日预算	合理设置日预算和总预算
事件质量	回传给平台的事件信号质量	优化事件埋点、选择正确的优化事件
竞争强度	同一受众池的其他广告主出价	选择竞争时段、调整受众策略

关键洞察：你买的不是「用户」，而是「平台对你广告的评估结果」。理解平台算法，才能优化你的输入。

流量主侧（Publisher Side）

关注点：如何通过广告变现赚钱（这是商业化增长的核心）。

核心能力：

- 广告位管理
- 瀑布流 / Header Bidding 配置
- 商业化 A/B 测试
- SSP 聚合
- 变现看板（eCPM、fill rate、ad ARPU、ad LTV）

关键洞察：买量和变现是同一枚硬币的两面。买量买来用户，变现从用户身上赚钱。ad LTV / CPI 是根本的 ROI 公式——提升 ad LTV（流量主侧）和降低 CPI（广告主侧）是同一目标的两

条路径。

6.3 广告平台演进与 Agentic Ads

Meta 商业化的五个阶段

理解广告平台的演进方向，才能预判平台能力的变化并提前布局：

阶段	时代	核心逻辑	广告主角色
社交广告	2004-2012	卖的是「人」不是「位」	选择人群包
移动效果广告	2012-2017	安装/付费/ROAS 优化	Campaign/Ad Set/Ad 三层结构
API 化与生态	2017-2021	Marketing API 开放给第三方	通过工具/API 操作
后隐私算法托管	2021-2025	Advantage+ 成默认，广告主提供信号	从操作者变成信号提供者
Agentic Ads	2025+	AI Agent 作为广告操作界面	从信号提供者变成意图描述者

趋势的核心：广告主的操作粒度越来越粗，平台自动化程度越来越高。但这不意味着广告主不重要了——广告主需要从操作者升级为策略者。

Marketing API 的演进

Meta Marketing API 从 v1 到 v25 的演化方向：从「暴露操作」到「封装平台策略」。

- v19: Objective 简化（6 种 → 3 种）
- v21: 旧 Campaign 无法扩量
- v24: ASC/AAC 旧创建方式被禁
- v25: 完全迁移到 Advantage+ Campaign Experience

启示：平台在强制推动广告主进入更自动化的投放模式。与其抗拒，不如提前建设 API 适配层，让每次 API 变更的影响最小化。

A2A 架构：Agent-to-Agent 的未来

未来的广告买量是 **A2A（Agent-to-Agent）** 架构：



跨平台策略	代表平台利益
长期品牌健康	短期效率最大化

两类 Agent 不是替代关系：

- 平台侧 Agent：理解平台，代表平台利益（让广告主多花钱、多转化）
- 广告主侧 Agent：理解业务，代表广告主利益（花最少的钱、获最好的用户）

它们有不同的权力边界和优化目标，需要共存。

Ad Agent 的核心能力

能力	说明
Intent	自然语言描述投放意图
Schema	将意图结构化为 API 可执行的操作
Adapter	适配不同广告平台的 API
Policy	分层信任/审批机制
Monitor	多窗口跟踪（花费、CPI、ROAS、留存）
Learner	操作日志和规则迭代

6.4 买量平台的技术架构

API 适配层

广告平台的 API 频繁变更（Meta 每季度一个版本），需要一个稳定的适配层：

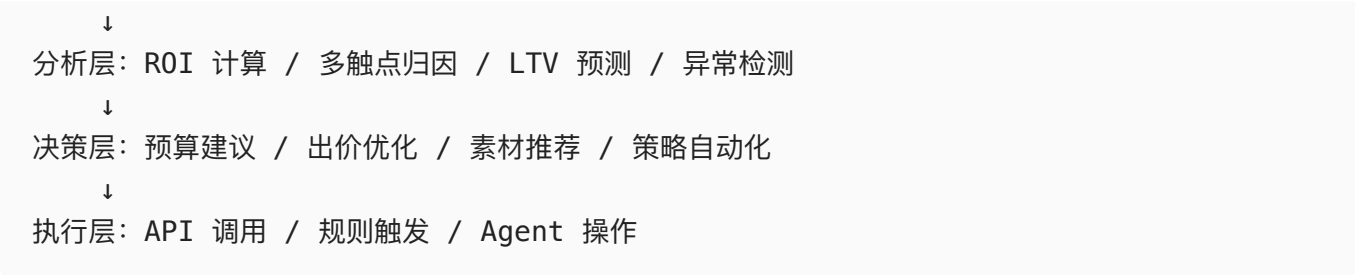
业务逻辑层 → API 适配层 → 各平台 API（Google/Meta/TikTok/...）

适配层的职责：

- 统一不同平台的 API 调用方式
- 屏蔽 API 版本差异
- 处理限流、重试、错误
- 版本治理作为季度常规工作

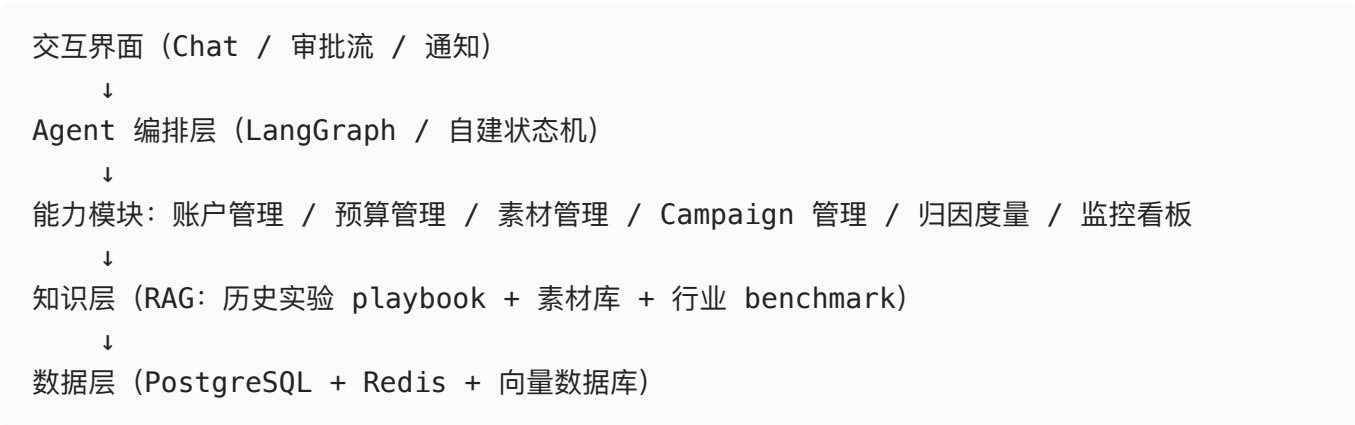
数据架构

数据源层：Google Ads API / Meta Marketing API / TikTok API / MMP / SDK
↓
数据管道：Airflow / 自建调度 → 数仓（BigQuery / ClickHouse / DuckDB）



Agent 架构

增长 Agent 的参考架构：



Human-in-the-Loop 的设计

Agent 的每一步操作都需要人的审批——这不是妥协，而是正确的分工：

操作类型	信任等级	审批要求
查看数据	高信任	无需审批
调整出价（±10%）	中信任	事后确认
暂停 Campaign	中信任	事前审批
新建 Campaign	低信任	事前审批 + 参数确认
修改归因配置	极低信任	事前审批 + 多人确认

6.5 买量平台建设的分阶段路径

阶段一：数据基础（4-6 周）

目标：L0 → L1 → L2

任务	说明
API 对接	Google Ads、Meta Ads、TikTok Ads 数据自动拉取

任务	说明
MMP 整合	AppsFlyer/Adjust 归因数据关联
统一看板	费用、CPI、ROAS 按渠道/国家/素材
LTV 计算	D7/D30 ROAS 计算

阶段二：效率工具（4-8 周）

目标：L2 → L3

任务	说明
自动化规则	CPI/ROAS 阈值自动暂停/降预算
批量操作	一键调价、一键开关、批量素材上传
素材管理	素材库、标签、A/B 测试管理
报表自动化	日报/周报自动生成和推送

阶段三：策略引擎 + AI Agent（8-16 周）

目标：L3 → L4 → L5

任务	说明
预算优化引擎	基于历史 ROI 的预算分配建议和自动调整
出价优化	Agent 自主调价（带审批机制）
素材 AI	AI 素材生成 + 自动 A/B 测试
Agent 编排	LangGraph/自建状态机，统一调度
Playbook 知识库	历史实验结论的 RAG 检索

6.6 托管 vs 自投：平台视角

两种模式的本质差异

维度	托管（Agency）	自投（In-house）
本质	花钱买结果	花钱建能力
数据	在代理手里	在自己手里
实验积累	代理的 playbook	自己的 playbook

维度	托管 (Agency)	自投 (In-house)
灵活性	受代理资源限制	完全自主
成本	长期高 (代理费 + 机会成本)	前期高 (人力 + 工具)、长期低

月消耗与模式选择

月消耗	建议模式	说明
< \$20K	托管	规模太小，不值得自建团队
\$20K-\$100K	视阶段而定	产品早期托管、验证后逐步自建
\$100K-\$300K	混合	核心渠道自投 + 非核心渠道托管
> \$300K	必须自投	数据和实验积累的价值远超代理费

自投团队建设路径

阶段一 (1-2 人, 单渠道):

- 1 个优化师 + 1 个数据分析师
- 单渠道 (通常 Meta 或 Google)
- 核心目标: 跑通买量流程, 积累基础数据

阶段二 (3-5 人, 多渠道):

- 2-3 个优化师 + 1 个素材 + 1 个数据
- Meta + Google + TikTok
- 核心目标: 跨渠道数据打通, 建立统一看板

阶段三 (8-15 人, 规模化):

- 4-6 个优化师 + 2-3 个素材 + 2 个数据 + 1 个平台
- 全渠道覆盖 + UA + ASO + KOL 协同
- 核心目标: 策略自动化, Agent 辅助决策

UA + ASO + KOL 的协同框架

协同场景	UA	ASO	KOL
关键词	付费搜索词指导 ASO 关键词	自然搜索排名提升降低品牌词 CPI	KOL 内容产生搜索量

协同场景	UA	ASO	KOL
素材	素材 USP 指导 ASO 截图	ASO 页面优化提高 CVR	KOL 创意反哺 UA 素材
受众	付费用户画像指导 ASO	自然用户画像反馈	KOL 粉丝画像验证
数据	付费获客数据	自然获客数据	归因数据（折扣码/深度链接）

6.7 极致利用广告平台

理解平台信号机制

广告平台的算法本质上是一个**信号处理系统**：

你的输入信号 → 平台算法 → 流量分配结果

信号质量决定结果质量：

信号	质量	影响
事件回传	高	平台能精准优化 → 更低 CPI / 更高 ROAS
事件回传	低	平台只能靠猜测 → 效果波动大
SKAN 回传	有限	只有聚合数据 → 优化精度受限

信号优化的实验

假设：将优化事件从「安装」改为「D3 留存用户」，CPI 上升 20% 但 D7 ROAS 提升 40%。

实验设计：

- **方法：**同素材同受众，创建两个 Ad Set，分别优化安装和 D3 留存
- **指标：**OEC = D7 ROAS；辅助 = CPI、D1 留存
- **时长：**21 天

版本治理

广告平台 API 频繁更新，需要建立版本治理机制：

1. **跟踪变更：**每季度检查 API changelog
2. **提前适配：**新版本上线前 2 个月开始适配
3. **灰度迁移：**先在新 Campaign 上使用新 API，旧 Campaign 保持不变

4. 全面迁移：确认无问题后全部迁移

把版本治理当作季度常规工作，而不是突发应对。

第七章 总结：实验方法在各行业的应用

7.1 跨行业的实验方法论

「实验即增长」不是某个行业的专属方法论，而是所有增长驱动型业务的通用逻辑。不同行业的差异在于：

维度	差异来源	影响
实验密度	功能迭代速度	内容平台 >> 电商 >> 游戏
样本量	DAU 量级	电商 > 内容平台 > 游戏
指标周期	LTV 回收周期	游戏（30-90 天） > 电商（7-30 天） > 内容（1-7 天）
权衡复杂度	商业化与体验的冲突	游戏（IAA vs 留存） > 内容（广告 vs 体验） > 电商（直接付费）

但核心逻辑不变：假设 → 设计 → 验证 → 沉淀 → 迭代。

7.2 内容平台

代表案例：快手

行业特点：

- DAU 数亿级，样本量极大
- 推荐算法是核心，实验密度极高
- 内容分发、搜索、广告、社交多维度交叉

实验重点：

- 推荐算法实验：每天数十个算法迭代，需要重叠流量框架
- 搜索实验：搜索排序、搜索 UI、搜索-推荐联动
- 广告实验：广告位、广告频次、广告与内容的边界
- 社交实验：关注流、推荐流、社交互动功能

关键挑战：推荐、搜索、广告高度耦合。一个推荐算法的改动可能影响广告收入，一个广告策略的变更可能影响搜索体验。实验平台必须支持跨域联合分析。

平台建设经验：

- 从互斥分流到重叠框架，实验并发量从 100+ 到 1000+
- 嵌套流量域：搜索域、推荐域、广告域各自独立但共享基础分流层
- Pre-AA 检验成为实验上线的必要条件

可复用方法：

- 重叠流量框架适用于所有高实验密度场景
- 跨域联合分析是解决耦合效应的必要手段
- 实验文化的建设比平台本身更重要

7.3 电商

代表案例：Shopee

行业特点：

- 交易型业务，指标直接关联 GMV
- 搜索、推荐、广告三大引擎驱动增长
- 跨地区运营，地区差异大

实验重点：

- **搜索实验**：搜索排序算法、搜索结果页 UI、筛选器设计
- **推荐实验**：首页推荐、商品详情页推荐、购物车推荐
- **促销实验**：优惠券策略、满减门槛、限时折扣
- **广告实验**：广告主侧出价策略、C端广告展示策略

关键挑战：

- **搜索-推荐-广告合并**：三者的目标函数不同（搜索追求相关性，推荐追求点击，广告追求收入），但共享同一屏的流量。实验必须考虑三者的交互效应。
- **地区差异**：东南亚各国的用户行为、品类结构、支付习惯差异巨大。一个在越南验证有效的策略，在巴西可能完全无效。

平台建设经验：

- 统一分散的实验平台为一个入口
- 支持跨域联合实验
- 自动化放量：5% → 50% → 100%

可复用方法：

- 统一实验平台避免流量冲突
- 跨域分析（global holdout实验）是发现交互效应的唯一手段
- 自动化放量减少人工操作错误

7.4 出海休闲游戏

行业特点

- DAU 从几万到数千万不等，起步阶段样本量有限
- IAA 是主要收入来源（广告占收入 70%+），商业化与体验的权衡尤为尖锐
- 买量是增长的主要引擎，CPI 和 ROAS 是生死线
- 产品迭代快，但 LTV 回收周期长（30-90 天）

三元增长模型的实践

出海休闲游戏是「三元增长模型」的典型场景：

产品留存 → LTV → CPI 承受力 → 买量规模 → 用户量 → 数据量 → 实验精度

↑
↓

广告收入 ← 商业化 ← 实验优化

三类实验必须联动：

1. 产品实验（留存）→ 决定 LTV 上限
2. 商业化实验（ARPU vs 留存）→ 决定 ad LTV
3. 买量实验（CPI vs ROAS）→ 决定获客效率和质量

分阶段增长路径

0 → 1（产品增长基础）：

- 目标：验证留存（D1 > 35%, D7 > 12%）
- 实验：新手引导、难度曲线、核心玩法变体
- 平台：基础事件 SDK + MMP + 简单 A/B 测试

1 → 10（验证变现 + 买量组合）：

- 目标：验证 ad LTV / CPI > 1（商业可行性）
- 实验：广告频次、广告位置、激励广告设计
- 实验：素材 A/B 测试、受众测试、出价策略测试
- 平台：统一买量看板 + 素材管理 + 商业化 A/B 测试

10 → 100（规模化增长系统）：

- 目标：建立可复制的增长飞轮
- 实验：跨渠道预算分配、个性化商业化、自动化投放
- 平台：策略引擎 + AI Agent + playbook 知识库

Block Blast! 的案例启示

Block Blast!（Hungry Studio）是 2026 年全球头部免费解谜游戏，其增长挑战提供了成熟期产品的典型样本：

三个预警信号：

1. 美国品类排名一度从 #1 下降到 #4 → 品类领导力被蚕食
2. 品牌搜索流量被克隆应用稀释 → 需要品牌防御
3. 无 AI 搜索可发现性基础设施 → 在新渠道中被动

增长策略的实验矩阵：

方向	实验	核心指标
品类领导力维持	UA-变现飞轮优化、Live Ops 联动、衰减监控	品类排名、DAU 趋势
搜索生态品牌防御	ASA 品牌词、克隆拦截、Google 品牌防御	品牌搜索份额
AI 搜索可发现性	GEO 技术优化、结构化数据、AI 搜索引擎监控	AI 搜索品牌提及率

渠道协同：

- 付费 UA × ASO：付费获客数据指导 ASO 关键词
- Live Ops × UA：活动期间加大投放，活动后观察留存
- UA × 变现飞轮：买量规模 → 用户量 → 广告填充 → eCPM → ad LTV → CPI 承受力

数据来源：

《Block Blast!》（Hungry Studio）2026 年全球头部免费解谜游戏，70M DAU、300M MAU 数据来自 Hungry Studio 官网 [1]、Business Wire 官方新闻稿 [2]、NextBigGames 行业深度报道 [3]；美国榜单波动、克隆应用流量侵蚀、AI 搜索渠道短板参考 Sensor Tower 榜单监测、Balancy 产品拆解报告 [4]；全域实验矩阵与渠道协同模型基于厂商万次 A/B 实验体系及海外休闲游戏增长行业通用方法论 [5]。

参考文献：

[1] Hungry Studio. Block Blast Official Brand Overview[EB/OL]. <https://www.blockblast.com>, 2026-03.

[2] Business Wire. Block Blast! Scales to 70M DAU as Hungry Studio Runs Over 10,000 Experiments in a Single Year[EB/OL]. 2026-01-08.

[3] NextBigGames. Block Blast! Hits 70M DAU & 300M MAU — Built on 10,000+ Tests[EB/OL].

2026-01-18.

[4] Balancy. How could Block Blast by Hungry Studio earn more? Product & Growth Deconstruction[EB/OL]. 2025-03-26.

[5] Udonis Mobile Marketing. Block Blast Revenue & Growth Flywheel Analysis 2026[EB/OL]. 2026-03.

[6] Deconstructor of Fun. From Tetris to Block Blast: Why Block Puzzles Never Stop Printing[EB/OL]. 2026-05-16.

7.5 其他行业的应用

SaaS / 企业服务

实验场景	典型实验	核心指标
转化漏斗	注册流程优化、定价页面设计	注册转化率、付费转化率
留存	Onboarding 流程、功能引导	D7/D30 活跃率、功能渗透率
定价	阶梯定价、年付折扣	ARPU、Churn Rate
获客渠道	SEM vs 内容营销 vs 社交	CAC、渠道 ROAS

特点：样本量小、决策周期长、LTV 高。需要更长的实验周期和更灵敏的统计方法（CUPED 尤其重要）。

电商（国内）

实验场景	典型实验	核心指标
搜索	排序算法、筛选器、搜索建议	搜索 CTR、搜索转化率
推荐	首页推荐、详情页推荐	推荐 CTR、推荐 GMV
促销	优惠券策略、满减门槛	促销 ROI、客单价
会员	会员权益设计、续费策略	会员转化率、续费率

特点：样本量大、指标时效性强（当天可看 GMV）、多维度交叉（搜索+推荐+促销+广告）。

教育科技

实验场景	典型实验	核心指标
学习效果	课程结构、练习频率、反馈机制	完课率、学习时长、测评分数
转化	试听课设计、定价策略	试听转化率、付费率
留存	学习提醒、社交激励	D7/D30 活跃率、续费率

特点：效果指标周期长（学习效果需要数周验证）、伦理约束（不能对学习效果做负面实验）。

7.6 实验方法论的跨行业规律

不变的规律

- 1. 因果推断是增长的基石 —— 无论行业如何，知道"什么导致了什么"永远是决策的前提
- 2. 实验闭环是学习的唯一路径 —— 假设 → 设计 → 验证 → 沉淀 → 迭代
- 3. 指标权衡无处不在 —— 没有免费的午餐，每个优化都有代价
- 4. 平台的目标是决策系统 —— 不是功能堆砌，而是让实验结论可积累、可复用

因行业而异的参数

参数	内容平台	电商	游戏	SaaS
实验密度	极高	高	中	低
样本量	极大	大	中	小
指标周期	短	中	长	长
权衡复杂度	中	中	高	低
首选统计方法	t 检验	t 检验	CUPED + 贝叶斯	CUPED + 序贯

AI 时代的统一方向

无论哪个行业，AI 都在推动增长系统走向同一个方向：

经验驱动 → 数据驱动 → 系统驱动 → Agent 驱动

但每一步的跃迁，都需要实验方法论的验证：

- 经验驱动 → 数据驱动：用实验验证经验是否可靠
- 数据驱动 → 系统驱动：用实验验证系统是否比人工更优
- 系统驱动 → Agent 驱动：用实验验证 Agent 的决策是否可信赖

AI 不改变增长的逻辑，但加速了增长系统的进化速度。实验方法论是确保这个加速不偏离轨道的导航系统。

7.7 结语

增长不是一次猜对，而是持续验证；不是单点爆发，而是实验复利。

在 AI 时代，我们有了更强大的工具——AI 可以生成素材、优化出价、预测 LTV、自动化投放。但工具再强大，也需要回答一个根本问题：它真的有效吗？

这个问题的答案，只能通过实验得到。

实验方法论不是增长的约束，而是增长的基石。不是因为有了实验平台才能做增长，而是因为要做增长，才需要实验平台。

从今天开始，养成三个习惯：

1. 先写假设，再动手优化
2. 每次只测一个变量
3. 每次实验后沉淀结论

增长不是玄学，是实验系统。

后记：方法论是廉价的，实操才能带来结果

写完这本书，我必须诚实地说一句：方法论是廉价的，实践和结果才重要。

你可以读完这本书，理解证据金字塔、重叠流量框架、三元增长模型、CUPED 方差缩减——然后什么都不做。知识不会自动变成业务结果。每一条经验教训背后，都是真金白银试出来的：

- 快手的重叠框架，是在流量碰撞导致结论不可信之后才建的
- Shopee 的跨域分析，是在搜索改版影响广告收入之后才重视的
- 出海游戏的 CUPED，是在样本量不够、实验跑不出显著性之后才引入的

知道不等于做到。做到不等于拿到结果。

如果你正在搭建增长系统、建设实验平台、或者试图把买量从「凭手感」变成「有体系」，你大概率会遇到这些问题：

- 理论看懂了，但第一步从哪开始？
- 平台搭了，但实验跑出来没人信、没人用
- 买量花了钱，但不知道该测什么、怎么测
- 团队没有实验文化，老板拍板、运营凭感觉

这些问题不是靠读一本书能解决的。它需要有人陪你一起踩坑、一起设计实验、一起把结论变成行动。

如果你需要一个咨询顾问，帮你把方法论建设成增长系统，拿到真实的业务结果——可以联系我。

微信: zhanbo_growth

网站: <https://abtest.chat>